Laporan Praktikum

IF4071 - Pemrosesan Ucapan

Pengenalan Vowel Bahasa Indonesia dengan DTW dan Model Gaussian



Disusun Oleh

Danendra Shafi Athallah 13523136

Jonathan Kenan Budianto 13523139

Jovandra Otniel Pangalambok Siregar 13523141

Muhammad Farrel Wibowo 13523153

Lukas Raja Agripa 13523158

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

2026

DAFTAR ISI

DAFTAR ISI **2**
1. Pendahuluan **3**
2. Program dan Dataset **4**
2.1. Link Program 4
2.1.1. Repositori dan Struktur Program 4
2.1.2. Preprocessing dan Ekstraksi Fitur MFCC 5
2.1.3. Sistem 1: DTW dengan Averaged Template 7
2.1.4. Sistem 2: Model Gaussian 8
2.1.5. Recognition dan Perhitungan Akurasi 9
2.2. Link Data 10
2.2.1. Repositori Data 10
2.2.2. Struktur dan Pembagian Dataset 10
2.2.3. Format dan Proses Perekaman 12
3. Hasil Eksperimen **13**
3.1. Konfigurasi Eksperimen 13
3.2. Ringkasan Akurasi Sistem 13
3.3. Akurasi untuk Setiap Vowel (Tabel 1) 14
3.4. Hasil Closed Experiments per Speaker (Tabel 2) 14
3.5. Hasil Open Experiments per Speaker (Tabel 3) 15
3.6. Confusion Matrix 16
4. Analisis Hasil **17**
4.1. Perbandingan DTW dan Model Gaussian 17
4.1.1. Akurasi Closed Scenario 17
4.1.2. Akurasi Open Scenario 18
4.1.3. Rata-rata Akurasi 19
4.1.4. Pengaruh Perbedaan Speaker 19
4.1.5. Pengaruh Averaged/Generalized Template 20
4.1.6. Kesalahan Pengenalan Vowel 22
4.2. Mengapa Performa DTW dan Gaussian Berbeda? 22
4.3. Mengapa Akurasi Closed dan Open Scenario Dapat Berbeda? 24
5. Penutup **25**
5.1. Kesimpulan 25
5.2. Saran 26
5.3. Pembagian Tugas 27
REFERENSI **28**

1. Pendahuluan

Praktikum ini bertujuan membangun dan membandingkan dua sistem pengenal ucapan untuk mengenali lima vowel Bahasa Indonesia, yaitu /a/, /i/, /u/, /e/, dan /o/. Sistem pertama adalah *template-based* ASR dengan *Dynamic Time Warping* (DTW) yang memakai *averaged template*, sedangkan sistem kedua adalah ASR berbasis Model Gaussian yang memakai *mean* dan *covariance* dengan *negative log-likelihood*.

Kedua sistem diimplementasikan dengan Python dan memakai fitur MFCC 39 dimensi. Pengujian dilakukan pada tiga skenario, yaitu *closed recordings*, *closed speakers*, dan *open speakers*. Hasilnya dibandingkan berdasarkan akurasi, pengaruh perbedaan speaker, pengaruh *averaged template*, dan kesalahan pengenalan vowel.

Laporan ini disusun dalam lima bab. Bab 1 memuat identitas kelompok dan tujuan praktikum. Bab 2 menjelaskan program dan dataset, meliputi ekstraksi fitur, kedua sistem pengenalan, serta struktur dan proses perekaman data. Bab 3 menyajikan hasil eksperimen berupa tabel akurasi dan *confusion matrix*. Bab 4 menganalisis hasil tersebut untuk menjawab dua pertanyaan wajib praktikum, dan Bab 5 memuat kesimpulan, saran, serta pembagian tugas.

2. Program dan Dataset

2.1. Link Program

2.1.1. Repositori dan Struktur Program

Seluruh *source code* program Python disimpan di repositori GitHub kelompok (https://github.com/jonathankenan/vowel-asr-dtw-vs-gaussian) agar dapat diakses. Program terdiri atas tujuh modul Python dan satu notebook, seperti pada Tabel 2.1. Modul `preprocessing.py`, `features.py`, `dtw.py`, dan `gaussian.py` menangani tahap pengenalan, `evaluation.py` menyusun

pipeline eksperimen dan metrik, `reporting.py` menyajikan hasil, dan `main.py` menjalankan seluruh eksperimen dari baris perintah. Notebook `dtw_gaussian.ipynb` hanya memanggil modul-modul tersebut untuk menampilkan tabel, sehingga `main.py` dan notebook menghasilkan angka yang sama (Bab 3).

Tabel 2.1. Komponen program

Komponen	Berkas	Keterangan
Preprocessing dan data loading	preprocessing.py	Memindai WAV secara rekursif, mengambil label vowel dan speaker dari nama folder atau berkas, serta mengubah audio menjadi mono 16 kHz
Ekstraksi MFCC 39 dimensi	features.py	Mengubah sinyal menjadi matriks fitur (frame × 39)
DTW	dtw.py	DTW, averaged template, dan recognition
Model Gaussian	gaussian.py	Mean, covariance, negative log-likelihood, dan recognition
Pengujian dan akurasi	evaluation.py	Pipeline eksperimen (run_experiment), perhitungan akurasi per skenario, vowel, dan speaker, serta confusion matrix
Penyajian hasil	reporting.py	Tabel hasil dan ekspor prediksi ke outputs/predictions.csv
Program utama	main.py	Menjalankan tiga skenario pengujian dari baris perintah dan mencetak seluruh tabel
Notebook eksplorasi	dtw_gaussian.ipynb	Antarmuka yang memanggil modul di atas dan menampilkan tabel

Dependensi program adalah `numpy`, `scipy`, dan `python_speech_features` (`requirements.txt`); notebook memerlukan Jupyter dan IPython tambahan. Program dijalankan dari direktori repositori dengan perintah `python main.py`, yang mencetak seluruh tabel akurasi dan menyimpan 270 baris prediksi ke `outputs/predictions.csv` (opsi `--root`, `--output`, dan `--no-csv` tersedia). Eksperimen dijalankan pada Python 3.11.9 dan diverifikasi ulang pada Python 3.13.7 dengan NumPy 2.3.4 dan SciPy 1.16.3 (Harris dkk., 2020; Virtanen dkk., 2020); hasil verifikasi ulang tersebut identik dengan berkas prediksi yang tersimpan.

2.1.2. Preprocessing dan Ekstraksi Fitur MFCC

Fungsi `load_records` pada `preprocessing.py` membaca seluruh berkas WAV di bawah folder tiap skenario secara rekursif dengan `scipy.io.wavfile.read`. Label vowel diambil dari akhiran nama berkas dengan ekspresi reguler yang tidak membedakan huruf besar dan kecil serta mengabaikan nomor pengambilan, sehingga `S01_A.wav`, `G09_S01_A01.wav`, dan `S2_Closed_i.wav` masing-masing terbaca sebagai /a/, /a/, dan /i/. Pada data *open*, nama folder (`open/A`, `open/E`, dan seterusnya) menjadi label utama dan nama berkas dipakai untuk validasi; seluruh 85 rekaman memiliki label folder dan nama berkas yang konsisten. Identitas speaker pada data template dan *closed* diambil dari nama folder tingkat pertama (`danen`, `kenan`, `jovan`, `farrel`, `lukas`), sedangkan pada data *open* diambil dari nama berkas tanpa token vowel (mis. `G09_S01_A01.wav` menjadi `G09_S01`).

Sebelum ekstraksi fitur, setiap rekaman diseragamkan oleh fungsi `prepare_audio`, yang dipanggil di awal `extract_mfcc`. Rekaman stereo (data S05 pada template dan *closed*) dirata-ratakan antarkanal menjadi mono, dan rekaman 48 kHz (data S05 dan S2_Closed) di-*resample* ke 16 kHz dengan `resample_poly` (rasio 1:3). Sinyal kemudian diubah menjadi bilangan riil `float64`. Program tidak memangkas jeda (*voice activity detection*) dan tidak melakukan normalisasi amplitudo maupun normalisasi rata-rata cepstral (CMVN), sehingga perbedaan perangkat dan tingkat rekaman antarspeaker langsung tercermin pada fitur (dibahas pada Bab 4).

Fitur diekstraksi oleh fungsi `extract_mfcc` di `features.py` yang memakai pustaka `python_speech_features` (Lyons, t.t.). Sinyal diproses dengan *pre-emphasis* (koefisien 0,97), dibagi menjadi *frame* 25 ms (400 sampel) dengan pergeseran 10 ms (160 sampel) tanpa fungsi jendela, diubah menjadi spektrum daya dengan FFT 512 titik, dilewatkan pada 26 filter mel, diambil logaritmanya, lalu ditransformasikan dengan DCT dan di-*lifter* (22) menjadi 13 koefisien

cepstral (Davis & Mermelstein, 1980). Koefisien ke-0 diganti dengan logaritma energi total *frame*. Tiga belas koefisien statis ini ditambah 13 koefisien delta dan 13 delta-delta yang dihitung dengan regresi atas ±2 *frame* (Furui, 1986), sehingga setiap *frame* menjadi vektor 39 dimensi. Keluarannya berupa matriks T × 39 dengan T antara 33 dan 341 *frame* per rekaman.

2.1.3. Sistem 1: DTW dengan Averaged Template

Sistem pertama membandingkan urutan *frame* masukan dengan satu *averaged template* untuk setiap vowel. Untuk dua deret vektor fitur $X = (x_1, ..., x_n)$ dan $Y = (y_1, ..., y_m)$, jarak lokal antar-*frame* adalah jarak Euclidean 39 dimensi, $d(i, j) = \|x_i - y_j\|$. Biaya kumulatif dihitung dengan rekursi tiga langkah standar (Sakoe & Chiba, 1978), dengan $D(i, 0) = D(0, j) = \infty$:

$$D(i, j) = d(i, j) + \min\{ D(i-1, j), D(i, j-1), D(i-1, j-1) \}, \quad D(0, 0) = 0 \qquad (1)$$

Lintasan penjajaran dipulihkan dengan penelusuran balik dari (n, m) ke (1, 1). Biaya akhir dinormalisasi dengan panjang lintasan K agar rekaman berdurasi berbeda dapat dibandingkan:

$$\text{cost}(X, Y) = D(n, m) \,/\, K \qquad (2)$$

Tidak dipakai pembatas jendela (*band*) maupun kemiringan selain tiga langkah tersebut, dan titik awal serta akhir lintasan dikunci pada (1, 1) dan (n, m).

Averaged template setiap vowel dibangun dari lima rekaman, masing-masing dari satu speaker pada folder template. Rekaman dengan panjang median dipilih sebagai referensi. Setiap rekaman (termasuk referensi) dijajarkan ke referensi dengan DTW; untuk setiap *frame* referensi, semua *frame* rekaman yang terjajar padanya dirata-ratakan. Hasil kelima rekaman kemudian dirata-ratakan *frame* demi *frame*, sehingga *template* memiliki panjang yang sama dengan rekaman referensi. Saat pengenalan, biaya DTW masukan terhadap kelima *template* dihitung dan vowel dengan biaya terkecil dipilih. Pseudo code ditunjukkan pada Pseudo code 2.1.

Pseudo code 2.1. DTW, pembentukan averaged template, dan pengenalan

```
FUNGSI DTW(X[1..n], Y[1..m])
  untuk i = 1..n dan j = 1..m: d[i][j] <- jarak_Euclidean(X[i], Y[j])
  D[0][0] <- 0;  D[i][0] <- D[0][j] <- tak hingga
  untuk i = 1..n:
    untuk j = 1..m:
      D[i][j] <- d[i][j] + min(D[i-1][j], D[i][j-1], D[i-1][j-1])
  path <- penelusuran balik dari (n, m) ke (1, 1) lewat sel
          predesesor yang D-nya terkecil
  kembalikan D[n][m] / panjang(path), path

FUNGSI BANGUN_TEMPLATE(F[1..5])            // 5 rekaman satu vowel
  ref <- rekaman dengan panjang median pada F
  total <- 0
  untuk setiap f pada F:
    (_, path) <- DTW(ref, f)
    untuk setiap frame i pada ref:
      A[i] <- rata-rata f[j] untuk semua (i, j) pada path
    total <- total + A
  kembalikan total / 5

FUNGSI PREDIKSI_DTW(X, T)                  // T = {vowel: template}
  untuk setiap vowel v: skor[v] <- DTW(X, T[v]).cost
  kembalikan vowel v dengan skor[v] terkecil
```

2.1.4. Sistem 2: Model Gaussian

Sistem kedua memodelkan setiap vowel dengan satu distribusi Gaussian multivariat 39 dimensi yang diestimasi dari seluruh *frame* kelima rekaman latih vowel tersebut (jumlah *frame*: /a/ 726, /i/ 721, /u/ 743, /e/ 778, dan /o/ 814). *Mean* dan *covariance* penuh diestimasi dengan metode *maximum likelihood* (Bishop, 2006), dengan N adalah jumlah *frame* latih vowel tersebut:

$$\mu = (1/N)\,\Sigma_{t=1..N}\,x_t, \quad \Sigma = (1/N)\,\Sigma_{t=1..N}\,(x_t - \mu)(x_t - \mu)^T \tag{3}$$

Karena *frame* yang berurutan sangat berkorelasi dan setiap vowel hanya memiliki lima rekaman, *covariance* diberi regularisasi berupa matriks diagonal. Skala dimensi sangat berbeda (log energi dan koefisien cepstral awal jauh lebih besar daripada delta), sehingga regularisasi dibuat sebanding dengan varians tiap dimensi, dengan batas bawah varians 10^{-6}:

$$\Sigma' = \Sigma + \mathrm{diag}(0{,}01 \cdot \sigma^2{}_k + 10^{-6}), \quad \sigma^2{}_k = \max(\Sigma_{kk}, 10^{-6}) \tag{4}$$

Skor sebuah rekaman uji $X = (x_1, \ldots, x_T)$ terhadap model vowel v adalah *negative log-likelihood* (NLL) yang dirata-ratakan per *frame* sehingga tidak bergantung pada durasi rekaman, dengan d = 39:

$$\mathrm{NLL}(X \mid v) = (1/T)\, \Sigma_{t=1..T}\, ½\, [\, d \ln(2\pi) + \ln|\Sigma_v| + (x_t - \mu_v)^T\, \Sigma_v^{-1}\, (x_t - \mu_v)\,] \quad (5)$$

Perhitungan memakai dekomposisi Cholesky $\Sigma = LL^T$ agar $\ln|\Sigma|$ dan bentuk kuadratik dapat dihitung secara stabil. Vowel dengan NLL terkecil menjadi hasil prediksi. Model ini tidak menyimpan urutan *frame*: setiap *frame* diperlakukan sebagai sampel yang independen. Pseudo code ditunjukkan pada Pseudo code 2.2.

Pseudo code 2.2. Pelatihan Gaussian, perhitungan NLL, dan pengenalan

```
FUNGSI LATIH_GAUSSIAN(F[1..5])              // 5 rekaman satu vowel
  X <- gabungkan seluruh frame dari F       // N x 39
  mu <- rata-rata kolom X
  Sigma <- (X - mu)^T (X - mu) / N
  Sigma <- Sigma + diag(0.01 * max(diag(Sigma), 1e-6) + 1e-6)
  kembalikan (mu, Sigma)

FUNGSI NLL(X[1..T], mu, Sigma)
  L <- Cholesky(Sigma)                       // Sigma = L L^T
  logdet <- 2 * jumlah(log(diag(L)))
  untuk t = 1..T:
    z <- selesaikan L z = X[t] - mu
    nll[t] <- 0.5 * (39 * log(2 * pi) + logdet + z^T z)
  kembalikan rata-rata(nll)

FUNGSI PREDIKSI_GAUSSIAN(X, M)              // M = {vowel: (mu, Sigma)}
  untuk setiap vowel v: skor[v] <- NLL(X, M[v].mu, M[v].Sigma)
  kembalikan vowel v dengan skor[v] terkecil
```

2.1.5. Recognition dan Perhitungan Akurasi

Setiap input diproses dengan alur audio, MFCC, perhitungan cost terhadap setiap template atau model, lalu vowel dengan cost terkecil dipilih sebagai hasil. Akurasi dihitung dengan rumus Accuracy = (jumlah prediksi benar / jumlah seluruh data uji) × 100%.

Fungsi *recognition* DTW adalah `predict_dtw` pada `dtw.py` dan fungsi *recognition* Model Gaussian adalah `predict_gaussian` pada `gaussian.py`; keduanya menerima matriks fitur satu rekaman dan mengembalikan satu vowel.

Alur lengkapnya: audio dikonversi ke mono 16 kHz, diubah menjadi matriks MFCC T × 39, dihitung skornya terhadap lima *template* atau lima model, lalu vowel dengan skor terkecil dipilih. Fungsi `accuracy` pada `evaluation.py` menghitung persentase prediksi benar pada sekumpulan rekaman. Akurasi per vowel dihitung terhadap rekaman dengan vowel aktual tersebut, akurasi per speaker dihitung terhadap rekaman milik speaker itu, dan baris *Average* pada Tabel 3.4 dan Tabel 3.5 adalah rata-rata sederhana antarspeaker. Kolom Rata-rata pada Tabel 3.2 adalah rata-rata sederhana atas tiga skenario, sehingga setiap skenario berbobot sama walaupun jumlah rekamannya berbeda (25, 25, dan 85).

2.2. Link Data

2.2.1. Repositori Data

Dataset rekaman vowel dapat diakses pada https://github.com/jonathankenan/vowel-asr-dtw-vs-gaussian/tree/main/data.

Dataset berada di repositori yang sama dengan program (folder `data/`), dan seluruh 135 berkas WAV (3,5 menit audio) ikut ter-*commit*.

2.2.2. Struktur dan Pembagian Dataset

Sesuai spesifikasi praktikum (Lestari, 2026), setiap anggota merekam lima vowel sebanyak dua kali, sehingga setiap anggota menghasilkan 10 rekaman dan kelompok menghasilkan 50 rekaman. Dataset dibagi menjadi tiga folder. Folder `template` berisi rekaman pertama setiap anggota untuk kelima vowel (5 anggota × 5 vowel = 25 rekaman) yang dipakai sebagai data latih. Folder `test/closed` berisi rekaman kedua dari anggota yang sama (25 rekaman), dan folder `test/open` berisi 85 rekaman dari 17 speaker anggota kelompok lain (5 vowel × 17 speaker). Pembagian data pada setiap skenario ditunjukkan pada Tabel 2.2.

Tabel 2.2. Pembagian data pada setiap skenario pengujian

Skenario	Folder	Sumber data	Jumlah rekaman
Closed recordings	data/template	Rekaman yang sama dengan yang dipakai untuk template	25
Closed speakers	data/test/closed	Speaker sama dengan template, rekaman berbeda	25
Open speakers	data/test/open	17 speaker dari kelompok lain, tidak dipakai untuk latih	85

Struktur folder dan penamaan berkas dibuat seragam agar dapat dibaca secara otomatis. Pada template dan *closed*, berkas diberi nama `<kode speaker>_<vowel>.wav` di dalam folder per anggota; pada *open*, berkas berada di folder per vowel dan diberi nama `<awalan kelompok>_<kode speaker>_<vowel>[nomor].wav`.

Komposisi data *open speakers* dirinci pada Tabel 2.3. Awalan nama berkas mengikuti penamaan dari kelompok penyedia data, dan setiap kode speaker dihitung sebagai satu speaker yang terpisah. Tidak semua awalan memiliki kelima kode speaker (G04 hanya S03 dan S04; Kel3 tidak memiliki S04), sehingga jumlah speaker *open* adalah 17.

Tabel 2.3. Komposisi data open speakers

Awalan berkas	Jumlah speaker	Kode speaker	Jumlah rekaman	Format audio
G04	2	S03, S04	10	16 kHz, mono
G07	5	S01–S05	25	16 kHz, mono
G09	5	S01–S05	25	16 kHz, mono
Kel3	4	S01, S02, S03, S05	20	16 kHz, mono
S2_Closed	1	–	5	48 kHz, mono
Total	**17**		**85**	

2.2.3. Format dan Proses Perekaman

Seluruh 135 berkas berformat WAV PCM 16-bit. Format yang ditargetkan adalah mono dengan sampling rate 16 kHz, tetapi tidak semua rekaman memenuhinya (Tabel 2.4): rekaman speaker S05 (template dan *closed*)

berformat 48 kHz stereo dan lima rekaman S2_Closed pada data *open* berformat 48 kHz mono. Perbedaan ini diseragamkan pada tahap preprocessing (Subbab 2.1.2) dan mengindikasikan bahwa rekaman dibuat dengan perangkat atau aplikasi yang tidak sama.

Tabel 2.4. Format audio dan durasi rekaman (detik; S01–S05 menggabungkan template dan closed)

Sumber data	Berkas	Format	Durasi rata-rata (min–maks)
S01 (Danendra)	10	16 kHz, mono	0,67 (0,36–0,95)
S02 (Kenan)	10	16 kHz, mono	1,35 (1,02–1,62)
S03 (Jovan)	10	16 kHz, mono	2,47 (2,13–2,88)
S04 (Farrel)	10	16 kHz, mono	1,45 (1,13–1,73)
S05 (Lukas)	10	48 kHz, stereo	1,52 (1,26–1,77)
Open: G04, G07, G09, Kel3	80	16 kHz, mono	1,52 (0,34–3,42)
Open: S2_Closed	5	48 kHz, mono	2,76 (2,60–2,86)
Seluruh data	**135**	**WAV PCM 16-bit**	**1,56 (0,34–3,42)**

Durasi rekaman sangat bervariasi, 0,34–3,42 detik (rata-rata 1,56 detik), atau 33–341 *frame* MFCC per rekaman. Rekaman S01 jauh lebih singkat (rata-rata 0,67 detik) daripada rekaman anggota lain (1,35–2,47 detik); perbedaan ini ikut dibahas pada Bab 4.

Data *open speakers* berasal dari anggota kelompok lain dengan awalan berkas G04, G07, G09, Kel3, dan S2_Closed (Tabel 2.3). Kelompok-kelompok tersebut tidak ikut membangun *template* maupun model, sehingga pengujian pada *open speakers* menguji generalisasi ke speaker, perangkat, dan kondisi rekaman yang belum pernah dilihat sistem.

3. Hasil Eksperimen

3.1. Konfigurasi Eksperimen

Tabel 3.1 memuat parameter yang dipakai pada ekstraksi fitur dan kedua sistem pengenalan.

Tabel 3.1. Parameter eksperimen

Komponen	Parameter	Nilai
MFCC	Sampling rate	16 kHz (rekaman 48 kHz di-resample; stereo dirata-ratakan menjadi mono)
MFCC	Panjang dan pergeseran frame	25 ms (400 sampel) dan 10 ms (160 sampel); tanpa fungsi jendela
MFCC	Jumlah koefisien, filterbank, dan NFFT	13 koefisien cepstral, 26 filter mel (0–8000 Hz), NFFT 512; pre-emphasis 0,97; lifter 22
MFCC	Delta dan delta-delta (total 39 dimensi)	13 statis (koefisien ke-0 diganti log energi frame) + 13 delta + 13 delta-delta; delta dari regresi ±2 frame
DTW	Jarak lokal dan constraint	Euclidean 39 dimensi; langkah (i–1, j), (i, j–1), (i–1, j–1); tanpa band; titik awal dan akhir dikunci; biaya dibagi panjang lintasan
DTW	Metode pembentukan averaged template	Referensi = rekaman bermedian panjang dari 5 rekaman; semua rekaman dijajarkan ke referensi dengan DTW, frame terjajar dirata-ratakan per frame referensi, lalu dirata-ratakan atas 5 rekaman
Gaussian	Bentuk covariance dan regularisasi	Satu Gaussian per vowel, full covariance 39 × 39 (ML, dibagi N); ditambah diag($0{,}01 \cdot \sigma^2 + 10^{-6}$); batas bawah varians 10^{-6}
Gaussian	Skor per rekaman (negative log-likelihood)	NLL rata-rata per frame (dekomposisi Cholesky); vowel dengan NLL terkecil dipilih
Data latih	Jumlah rekaman latih	25 rekaman (5 speaker × 5 vowel), yaitu 5 rekaman per vowel

3.2. Ringkasan Akurasi Sistem

Tabel 3.2 merangkum akurasi kedua sistem pada tiga skenario pengujian.

Tabel 3.2. Ringkasan akurasi DTW dan Model Gaussian

Sistem	Closed Recording	Closed Speakers	Open Speakers	Rata-rata
DTW Template	100,00%	88,00%	67,06%	85,02%
Model Gaussian	100,00%	76,00%	40,00%	72,00%

Jumlah prediksi benar adalah 25/25, 22/25, dan 57/85 untuk DTW, serta 25/25, 19/25, dan 34/85 untuk Model Gaussian. Kolom Rata-rata adalah rata-rata sederhana atas ketiga skenario. Closed Recording memakai data yang sama dengan data latih sehingga bukan ukuran generalisasi; bila hanya dua skenario

dengan data baru yang dirata-ratakan, DTW mencapai 77,53% dan Model Gaussian 58,00%.

3.3. Akurasi untuk Setiap Vowel (Tabel 1)

Tabel 3.3 memuat akurasi kedua sistem untuk setiap vowel pada tiga skenario pengujian.

Tabel 3.3. Akurasi untuk setiap vowel

Vowel	DTW Closed Recording	DTW Closed Speakers	DTW Open Speakers	Gaussian Closed Recordings	Gaussian Closed Speakers	Gaussian Open Speakers
a	100,00%	100,00%	52,94%	100,00%	100,00%	88,24%
i	100,00%	100,00%	82,35%	100,00%	100,00%	70,59%
u	100,00%	80,00%	47,06%	100,00%	40,00%	11,76%
e	100,00%	60,00%	82,35%	100,00%	80,00%	17,65%
o	100,00%	100,00%	70,59%	100,00%	60,00%	11,76%
Average Accuracy	**100,00%**	**88,00%**	**67,06%**	**100,00%**	**76,00%**	**40,00%**

3.4. Hasil Closed Experiments per Speaker (Tabel 2)

Tabel 3.4 memuat akurasi pada closed experiments untuk setiap speaker.

Tabel 3.4. Hasil closed experiments per speaker

Speakers	DTW Closed Recording	DTW Closed Speakers	Gaussian Closed Recordings	Gaussian Closed Speakers	Average
S01 (Danendra)	100,00%	60,00%	100,00%	60,00%	80,00%
S02 (Kenan)	100,00%	100,00%	100,00%	80,00%	95,00%
S03 (Jovan)	100,00%	100,00%	100,00%	80,00%	95,00%
S04 (Farrel)	100,00%	100,00%	100,00%	100,00%	100,00%
S05 (Lukas)	100,00%	80,00%	100,00%	60,00%	85,00%
Average	**100,00%**	**88,00%**	**100,00%**	**76,00%**	**91,00%**

3.5. Hasil Open Experiments per Speaker (Tabel 3)

Tabel 3.5 memuat akurasi pada open experiments untuk setiap speaker dari kelompok lain.

Tabel 3.5. Hasil open experiments per speaker

Speakers	DTW Open	Gaussian Open	Average
G04_S03	60,00%	40,00%	50,00%
G04_S04	40,00%	20,00%	30,00%
G07_S01	80,00%	40,00%	60,00%
G07_S02	40,00%	60,00%	50,00%
G07_S03	80,00%	40,00%	60,00%
G07_S04	80,00%	40,00%	60,00%
G07_S05	60,00%	40,00%	50,00%
G09_S01	80,00%	60,00%	70,00%
G09_S02	80,00%	60,00%	70,00%
G09_S03	80,00%	40,00%	60,00%
G09_S04	60,00%	20,00%	40,00%
G09_S05	80,00%	40,00%	60,00%
Kel3_S01	80,00%	20,00%	50,00%
Kel3_S02	60,00%	40,00%	50,00%
Kel3_S03	40,00%	20,00%	30,00%
Kel3_S05	40,00%	20,00%	30,00%
S2_Closed	100,00%	80,00%	90,00%
Average	**67,06%**	**40,00%**	**53,53%**

Baris diberi nama sesuai awalan berkas dan kode speaker (mis. G07_S02) karena data *open* berasal dari kelompok lain; terdapat 17 speaker. Baris Average adalah rata-rata antarspeaker, yang sama dengan akurasi gabungan 85 rekaman karena setiap speaker memiliki lima rekaman uji. Akurasi DTW berkisar 40,00%–100,00% dan Model Gaussian 20,00%–80,00% antarspeaker. DTW lebih tinggi pada 16 dari 17 speaker. Karena setiap speaker hanya memiliki lima rekaman uji, satu kesalahan menurunkan akurasi speaker sebesar 20 poin persentase.

3.6. Confusion Matrix

Tabel 3.6 dan Tabel 3.7 memuat confusion matrix yang menjadi dasar analisis kesalahan pengenalan vowel pada Subbab 4.1.6, sedangkan Tabel 3.8 merinci kesalahan pada closed speakers. Cakupan data pada kedua matriks adalah

seluruh 85 rekaman *open speakers* (17 rekaman per vowel), karena skenario ini menguji generalisasi dan memuat kesalahan paling banyak. Baris adalah vowel sebenarnya, kolom adalah vowel prediksi, dan nilai adalah jumlah rekaman; angka tebal pada diagonal adalah prediksi benar.

Tabel 3.6. Confusion matrix sistem DTW

Aktual \ Prediksi	***/a/***	***/i/***	***/u/***	***/e/***	***/o/***
/a/	**9**	2	1	3	2
/i/	0	**14**	0	3	0
/u/	0	0	**8**	0	9
/e/	0	2	0	**14**	1
/o/	2	0	3	0	**12**

Tabel 3.7. Confusion matrix sistem Model Gaussian

Aktual \ Prediksi	***/a/***	***/i/***	***/u/***	***/e/***	***/o/***
/a/	**15**	2	0	0	0
/i/	5	**12**	0	0	0
/u/	9	1	**2**	0	5
/e/	10	4	0	**3**	0
/o/	15	0	0	0	**2**

Pada closed speakers, DTW salah pada 3 rekaman dan Model Gaussian pada 6 rekaman; rinciannya ditunjukkan pada Tabel 3.8.

Tabel 3.8. Rekaman closed speakers yang salah dikenali

Sistem	**Speaker**	**Vowel aktual**	**Vowel prediksi**
DTW	S01 (Danendra)	/e/	/i/
DTW	S01 (Danendra)	/u/	/i/
DTW	S05 (Lukas)	/e/	/u/
Gaussian	S01 (Danendra)	/o/	/a/
Gaussian	S01 (Danendra)	/u/	/i/
Gaussian	S03 (Jovan)	/u/	/o/
Gaussian	S02 (Kenan)	/u/	/a/

Sistem	Speaker	Vowel aktual	Vowel prediksi
Gaussian	S05 (Lukas)	/e/	/a/
Gaussian	S05 (Lukas)	/o/	/a/

4. Analisis Hasil

4.1. Perbandingan DTW dan Model Gaussian

4.1.1. Akurasi Closed Scenario

Pada *closed recordings* kedua sistem mencapai akurasi 100,00% (25 dari 25 rekaman; Tabel 3.2 dan 3.4). Hasil ini wajar karena data uji identik dengan data latih: setiap rekaman menyumbang seperlima *averaged template* DTW dan seluruh *frame*-nya ikut membentuk *mean* dan *covariance* Gaussian. Akurasi 100,00% hanya menunjukkan bahwa kedua model mampu memisahkan data latihnya sendiri, bukan kemampuan mengenali rekaman baru, sehingga angka ini tidak dipakai sebagai dasar membandingkan kedua sistem.

Pada *closed speakers*, yaitu speaker yang sama dengan rekaman yang berbeda, akurasi turun menjadi 88,00% (22 dari 25) untuk DTW dan 76,00% (19 dari 25) untuk Model Gaussian, atau turun 12,00 dan 24,00 poin persentase dari *closed recordings*. DTW salah pada tiga rekaman (/e/ dan /u/ milik S01 terbaca /i/, serta /e/ milik S05 terbaca /u/), sedangkan Model Gaussian salah pada enam rekaman, empat di antaranya terbaca /a/ (Tabel 3.8). Selisih kedua sistem sebesar 12,00 poin setara tiga rekaman; dengan hanya 25 rekaman uji, selisih ini belum kuat secara statistik (uji McNemar eksak: DTW benar sendiri pada 4 rekaman dan Gaussian benar sendiri pada 1 rekaman, $p = 0{,}375$). Penurunan dari *closed recordings* menunjukkan adanya variasi antarrekaman pada speaker yang sama, misalnya durasi /a/ milik S01 berubah dari 0,815 detik pada template menjadi 0,364 detik pada rekaman *closed*.

4.1.2. Akurasi Open Scenario

Pada *open speakers*, akurasi DTW adalah 67,06% (57 dari 85) dan Model Gaussian 40,00% (34 dari 85), atau selisih 27,06 poin persentase untuk

keunggulan DTW. Dibanding *closed speakers*, DTW turun 20,94 poin dan Model Gaussian turun 36,00 poin, sehingga Model Gaussian adalah sistem yang lebih terpengaruh oleh pergantian speaker. Dengan lima kelas yang seimbang, tebakan acak menghasilkan akurasi 20%; DTW berada sekitar 3,4 kali di atasnya, sedangkan Model Gaussian hanya dua kali. DTW lebih tinggi pada 16 dari 17 speaker (Tabel 3.5); satu-satunya pengecualian adalah G07_S02 (DTW 40,00%, Gaussian 60,00%).

Pada 85 rekaman *open*, DTW benar sendiri pada 29 rekaman, Model Gaussian benar sendiri pada 6 rekaman, 28 rekaman benar pada keduanya, dan 22 rekaman salah pada keduanya. Uji McNemar eksak memberi $p \approx 0{,}0001$ (dengan asumsi rekaman saling independen), sehingga keunggulan DTW pada *open speakers* sangat kecil kemungkinannya terjadi karena kebetulan. Satu speaker, S2_Closed, memiliki akurasi tertinggi (100,00% dan 80,00%); tanpa speaker ini akurasi *open* menjadi 65,00% untuk DTW dan 37,50% untuk Model Gaussian, sehingga kesimpulan tidak berubah.

4.1.3. Rata-rata Akurasi

Rata-rata akurasi tiga skenario adalah 85,02% untuk DTW dan 72,00% untuk Model Gaussian, selisih 13,02 poin persentase. DTW sama dengan Model Gaussian pada *closed recordings* dan lebih tinggi pada dua skenario lainnya, sehingga DTW lebih baik secara keseluruhan. Karena *closed recordings* bernilai 100,00% pada kedua sistem dan tidak mengukur generalisasi, selisih pada dua skenario berdata baru lebih informatif: rata-rata *closed speakers* dan *open speakers* adalah 77,53% untuk DTW dan 58,00% untuk Model Gaussian (selisih 19,53 poin). Bila seluruh 135 rekaman digabung tanpa pembobotan skenario, hasilnya 77,04% (104/135) untuk DTW dan 57,78% (78/135) untuk Model Gaussian; urutan kedua sistem tidak berubah.

4.1.4. Pengaruh Perbedaan Speaker

Pada *closed speakers* (Tabel 3.4), speaker S04 (Farrel) dikenali sempurna oleh kedua sistem, sedangkan S01 (Danendra) paling sulit dengan 60,00% pada DTW maupun Model Gaussian; S05 (Lukas) berikutnya dengan 80,00% (DTW) dan 60,00% (Gaussian). Rekaman S01 adalah yang tersingkat di dataset (rata-rata 0,67 detik, sedangkan speaker lain 1,35–2,47 detik; Tabel 2.4). Dugaan kami, rekaman yang sangat singkat didominasi bagian awal dan akhir ucapan yang kurang mencerminkan vowel yang stabil sehingga lebih mudah tertukar dengan vowel lain; tiga dari empat kesalahan S01 memang jatuh ke /i/. Rekaman S05 berformat 48 kHz stereo dan harus di-*downmix* serta di-*resample*; apakah hal ini berkaitan dengan akurasinya yang lebih rendah tidak dapat dipastikan dari data yang ada.

Pada *open speakers* (Tabel 3.5), akurasi DTW antarspeaker berkisar 40,00%–100,00% dan Model Gaussian 20,00%–80,00%. Speaker tersulit pada kedua sistem adalah G04_S04, Kel3_S03, dan Kel3_S05 (DTW 40,00%, Gaussian 20,00%), sedangkan speaker termudah adalah S2_Closed (100,00% dan 80,00%). Dirata-ratakan per kelompok sumber, DTW mencapai 76,00% pada G09, 68,00% pada G07, 55,00% pada Kel3, dan 50,00% pada G04, sedangkan Model Gaussian mencapai 44,00%, 44,00%, 25,00%, dan 30,00%. Pola antarkelompok ini mengisyaratkan bahwa kondisi rekaman yang dibawa tiap kelompok (perangkat, jarak mikrofon, ruangan) kemungkinan berpengaruh. Dugaan ini tidak dapat diuji karena repositori tidak memuat metadata perangkat, ruangan, maupun gender speaker; karena itu laporan ini tidak menyimpulkan pengaruh gender atau perangkat. Selain itu, setiap speaker hanya diuji dengan lima rekaman sehingga perbedaan antarspeaker individual sebaiknya dibaca sebagai indikasi, bukan ukuran yang pasti.

4.1.5. Pengaruh Averaged/Generalized Template

Averaged template DTW merangkum lima speaker sekaligus: setiap rekaman dijajarkan ke rekaman referensi lalu dirata-ratakan, sehingga ciri khas satu speaker (kecepatan, nada, dan durasi yang berkisar 0,38–2,88 detik pada rekaman latih) tereduksi dan yang tersisa adalah lintasan fitur rata-rata sebuah vowel. *Template* semacam ini lebih tahan terhadap speaker baru dibanding sebuah rekaman tunggal, sejalan dengan DTW yang tetap mencapai 67,06% pada speaker yang belum dikenal. Namun, rata-rata atas hanya lima speaker belum mewakili variasi suara yang luas, dan rata-rata juga dapat mengaburkan perbedaan vowel yang berdekatan; hal ini konsisten dengan kesalahan /u/ → /o/ pada 9 dari 17 rekaman (Tabel 3.6). Eksperimen ini tidak membandingkan secara langsung dengan *template* per speaker, sehingga besar efek rata-rata tidak dapat dikuantifikasi; pembanding terdekat adalah turunnya akurasi dari *closed speakers* ke *open speakers* (20,94 poin), yang menunjukkan bahwa *template* paling cocok dengan speaker yang ikut membentuknya.

Model Gaussian juga digeneralisasi dari kelima speaker, tetapi dengan kapasitas yang jauh lebih besar: setiap vowel memiliki 39 parameter *mean* dan 780 parameter *covariance* (39 × 40 / 2) yang diestimasi dari 721–814 *frame* yang berasal dari hanya lima rekaman dan berkorelasi kuat. Estimasi seperti ini cenderung menyesuaikan diri dengan kelima speaker latih. Akibatnya terlihat pada Tabel 4.1: model /a/ memiliki $\ln|\Sigma|$ terbesar (65,55), artinya distribusinya paling lebar, dan untuk rekaman /o/, /u/, serta /e/ dari speaker *open*, model /a/ memberi rata-rata NLL yang lebih rendah (96,49; 96,83; dan 105,21) daripada model vowel yang benar (105,11; 105,13; dan 107,77). Inilah sebabnya 54 dari 85 prediksi Model Gaussian adalah /a/ (63,5%), padahal setiap vowel hanya 17 rekaman (20%). Model /u/ yang paling sempit ($\ln|\Sigma| = 50,39$) paling dirugikan oleh speaker baru.

Tabel 4.1. Rata-rata NLL per frame rekaman open speakers terhadap setiap model Gaussian

Rekaman vowel (aktual)	Model /a/	Model /i/	Model /u/	Model /e/	Model /o/
/a/	**98,09**	107,04	123,86	110,56	110,02
/i/	106,87	**101,67**	145,86	114,71	119,17
/u/	**96,83**	101,88	105,13	104,24	97,75
/e/	**105,21**	111,66	132,42	107,77	115,77
/o/	**96,49**	108,59	117,02	110,52	105,11
ln|Σ| model	65,55	65,12	50,39	58,37	56,33

Setiap sel adalah rata-rata, atas 17 rekaman *open* dengan vowel aktual pada baris tersebut, dari NLL rata-rata per *frame* terhadap model pada kolom. Angka tebal adalah NLL terkecil pada baris (model yang dipilih bila rata-rata menentukan). Baris terakhir memuat ln|Σ| tiap model. Perhitungan ini tambahan, memakai model dan fungsi `score_gaussian` yang sama dengan pipeline `evaluation.py` tetapi tidak termasuk keluaran `main.py` maupun notebook.

4.1.6. Kesalahan Pengenalan Vowel

Pada DTW (Tabel 3.6), 28 dari 85 rekaman *open* salah dikenali. Kesalahan terbanyak adalah /u/ → /o/ pada 9 dari 17 rekaman (52,94% dari seluruh rekaman /u/), diikuti /a/ → /e/, /i/ → /e/, dan /o/ → /u/ masing-masing 3 rekaman. Pasangan /u/–/o/ (9 + 3 = 12 kesalahan) dan /i/–/e/ (3 + 2 = 5 kesalahan) menyumbang 17 dari 28 kesalahan (60,7%). Kedua pasangan itu bertetangga di ruang vowel: /u/ dan /o/ sama-sama vowel belakang bulat, /i/ dan /e/ sama-sama vowel depan, dan masing-masing hanya berbeda tinggi lidah, sehingga bentuk spektrum keduanya berdekatan dan mudah tertukar, terlebih bila pengucapan speaker tidak persis sama. Vowel /a/ benar pada 9 dari 17 rekaman dan kesalahannya tersebar ke keempat kelas lain (/e/ 3, /i/ 2, /o/ 2, /u/ 1) tanpa satu tetangga yang dominan.

Pada Model Gaussian (Tabel 3.7), 51 dari 85 rekaman salah dan 39 di antaranya (76,5%) diprediksi sebagai /a/: /o/ → /a/ pada 15 dari 17 rekaman, /e/ → /a/ pada 10, /u/ → /a/ pada 9, dan /i/ → /a/ pada 5. Pola ini bukan kemiripan akustik antarvowel, melainkan bias model: model /a/ yang lebar menyerap rekaman

speaker asing (Subbab 4.1.5). Akibatnya /u/, /e/, dan /o/ hanya dikenali pada 2, 3, dan 2 dari 17 rekaman. Kesalahan lain Model Gaussian yang tidak mengarah ke /a/ adalah /u/ → /o/ (5) dan /e/ → /i/ (4).

Berdasarkan Tabel 3.3, /u/ memiliki akurasi terendah pada *open speakers* untuk kedua sistem (DTW 47,06%; Gaussian 11,76%, sama dengan /o/) dan pada *closed speakers* untuk Model Gaussian (40,00%). Pada *closed speakers* DTW, vowel terendah adalah /e/ (60,00%), dengan kesalahan /e/ → /i/ pada S01 dan /e/ → /u/ pada S05. Sebaliknya /i/ paling stabil: 100,00% pada *closed speakers* untuk kedua sistem, serta 82,35% (DTW) dan 70,59% (Gaussian) pada *open speakers*.

4.2. Mengapa Performa DTW dan Gaussian Berbeda?

DTW lebih unggul daripada Model Gaussian, dan keunggulannya membesar seiring bertambahnya ketidakcocokan antara data uji dan data latih: selisih 0,00; 12,00; dan 27,06 poin persentase pada *closed recordings*, *closed speakers*, dan *open speakers*. Dua sifat kedua model menjelaskan perbedaan ini.

DTW membandingkan rekaman dengan *template* secara berurutan dan menjajarkan *frame* melalui *warping*, sehingga lintasan fitur dari awal hingga akhir vowel ikut dibandingkan dan perbedaan durasi (0,34–3,42 detik) ditangani oleh penjajaran. Model Gaussian merangkum seluruh *frame* sebagai himpunan sampel independen; urutan hilang, dan *frame* transisi atau jeda di awal dan akhir rekaman (yang tidak dipangkas pada program ini) dihitung setara dengan *frame* vowel yang stabil. Informasi dinamik hanya tersisa sebagian pada koefisien delta dan delta-delta. Untuk vowel yang diucapkan stabil, informasi urutan relatif sedikit, sehingga faktor ini saja tidak menjelaskan seluruh selisih.

Template DTW berupa rata-rata lintasan fitur tanpa parameter sebaran, sedangkan Model Gaussian menaksir 819 parameter per vowel dari hanya lima rekaman. Sebaran yang diestimasi sempit untuk speaker latih menjadi tidak sesuai pada speaker baru, dan karena skor NLL memuat $\ln|\Sigma|$, model terlebar (/a/)

menang pada data asing (Tabel 4.1). Hasilnya Model Gaussian hampir runtuh ke /a/ pada *open speakers* (54 dari 85 prediksi), sedangkan sebaran prediksi DTW jauh lebih merata (11–24 prediksi per vowel) dan kesalahannya terpusat pada pasangan vowel yang bertetangga (Subbab 4.1.6). Faktor kedua ini yang paling jelas terlihat pada data: bias ke /a/ menjelaskan mengapa selisih kedua sistem melonjak pada *open speakers*.

Kedua kesimpulan ini berlaku untuk konfigurasi dan jumlah data praktikum ini (lima speaker latih, satu rekaman per vowel per speaker, fitur MFCC tanpa normalisasi) dan tidak berarti bahwa model Gaussian secara umum lebih lemah daripada DTW. Dengan data latih lebih banyak, *covariance* yang dipakai bersama, campuran Gaussian, atau HMM yang memodelkan urutan waktu, urutan keunggulan dapat berubah.

4.3. Mengapa Akurasi Closed dan Open Scenario Dapat Berbeda?

Akurasi turun berurutan dari *closed recordings* ke *closed speakers* ke *open speakers*: DTW 100,00% → 88,00% → 67,06% dan Model Gaussian 100,00% → 76,00% → 40,00%. Besar penurunannya ditunjukkan pada Tabel 4.2.

Tabel 4.2. Penurunan akurasi antarskenario (poin persentase)

Sistem	Closed Recording → Closed Speakers	Closed Speakers → Open Speakers	Closed Recording → Open Speakers
DTW	12,00	20,94	32,94
Model Gaussian	24,00	36,00	60,00

Terdapat beberapa faktor yang memengaruhi perbedaan skenario *closed* dan *open*. **Pertama, data uji sama dengan data latih.** *Closed recordings* menguji sistem pada rekaman yang ikut membentuk *template* dan model,

sehingga akurasinya 100,00% pada kedua sistem dan tidak mencerminkan kemampuan pada data baru.

Kedua, variasi dalam satu speaker. Pada *closed speakers*, suara speaker sudah ikut membentuk model (satu dari lima kontributor), tetapi rekamannya berbeda. Durasi, kecepatan, dan artikulasi ucapan berubah antarpengambilan (mis. /a/ milik S01: 0,815 detik pada template dan 0,364 detik pada rekaman *closed*; /e/: 0,379 detik menjadi 0,954 detik). Variasi ini sudah menurunkan akurasi sebesar 12,00 poin (DTW) dan 24,00 poin (Gaussian).

Ketiga, variasi antar-*speaker* dan kondisi rekaman. Pada *open speakers*, speaker belum pernah dilihat model. Panjang saluran suara, nada dasar, dan cara mengucapkan vowel yang berbeda menggeser spektrum, sementara perangkat, ruangan, tingkat rekaman, dan sampling rate (16 kHz dan 48 kHz) juga berbeda antarsumber. Program tidak menormalkan amplitudo maupun rata-rata cepstral, dan koefisien ke-0 adalah log energi *frame*, sehingga tingkat rekaman langsung memengaruhi fitur. Penurunan dari *closed speakers* ke *open speakers* sebesar 20,94 poin (DTW) dan 36,00 poin (Gaussian) menunjukkan bahwa faktor-faktor ini lebih berat daripada variasi dalam satu speaker.

Keempat, sedikitnya data latih. Model hanya melihat lima speaker dengan satu rekaman per vowel per speaker (25 rekaman latih). Daerah variasi vowel yang tercakup sangat sempit, sehingga speaker yang suaranya jauh dari kelima speaker latih berada di luar daerah itu; sistem yang lebih peka terhadap ketidakcocokan distribusi (Model Gaussian) turun paling banyak.

Kelima, kecilnya ukuran data uji. *Closed speakers* hanya terdiri atas 25 rekaman (satu rekaman setara 4 poin persentase), sedangkan *open speakers* terdiri atas 85 rekaman dari 17 speaker (satu rekaman setara 1,18 poin). Estimasi pada *open speakers* karenanya lebih stabil dan lebih mewakili penggunaan nyata sistem.

5. Penutup

5.1. Kesimpulan

Praktikum ini membangun dan membandingkan dua sistem pengenal lima vowel Bahasa Indonesia (/a/, /i/, /u/, /e/, /o/) dengan fitur MFCC 39 dimensi: DTW dengan *averaged template* dan Model Gaussian (*full covariance*, *negative log-likelihood*). Kedua sistem dilatih dari 25 rekaman (5 speaker × 5 vowel) dan diuji pada tiga skenario.

Akurasi DTW adalah 100,00% pada *closed recordings*, 88,00% pada *closed speakers*, dan 67,06% pada *open speakers* dengan rata-rata 85,02%, sedangkan Model Gaussian memperoleh 100,00%, 76,00%, dan 40,00% dengan rata-rata 72,00% (Tabel 3.2). DTW lebih baik pada skenario dengan data baru, terutama pada *open speakers* (selisih 27,06 poin; DTW lebih tinggi pada 16 dari 17 speaker; uji McNemar eksak $p \approx 0{,}0001$).

Keunggulan DTW dijelaskan oleh pembandingan urutan *frame* melalui penjajaran waktu dan oleh modelnya yang lebih sederhana. Model Gaussian dengan 819 parameter per vowel yang diestimasi dari lima rekaman menjadi bias ke model terlebar (/a/) pada speaker baru, sehingga 54 dari 85 prediksinya adalah /a/ (Tabel 4.1). Kesalahan DTW terpusat pada pasangan vowel bertetangga /u/–/o/ dan /i/–/e/ (Tabel 3.6).

Penurunan akurasi dari *closed* ke *open* mencerminkan variasi antarspeaker dan kondisi rekaman serta sedikitnya data latih, sedangkan akurasi 100,00% pada *closed recordings* hanya menunjukkan kecocokan dengan data latih. Pengaruh perangkat, ruangan, dan gender tidak dapat diuji karena tidak tercatat pada dataset.

5.2. Saran

1. Perbanyak dan variasikan data latih. Setiap vowel hanya memiliki lima rekaman latih, dan akurasi turun 20,94–36,00 poin pada speaker baru.

Tambahkan speaker dan pengambilan ulang per speaker, serta evaluasi dengan skema *leave-one-speaker-out* agar seluruh data open dapat dimanfaatkan.

2. Seragamkan perekaman dan catat metadata. Rekam langsung pada 16 kHz mono (S05 dan S2_Closed berformat 48 kHz), tetapkan durasi minimum dan cara pengucapan (rekaman S01 hanya 0,36–0,95 detik), serta catat perangkat, ruangan, dan gender agar pengaruhnya dapat diuji (Subbab 4.1.4).

3. Tambahkan normalisasi fitur. Terapkan CMVN, pemangkasan jeda, dan normalisasi atau pembuangan log energi karena tingkat rekaman yang berbeda memengaruhi fitur (Subbab 4.3).

4. Perbaiki Model Gaussian. Gunakan *covariance* yang dipakai bersama antarvowel atau diagonal, regularisasi yang lebih kuat, campuran Gaussian, atau HMM agar bias ke model terlebar berkurang (Tabel 4.1) dan urutan waktu ikut dimodelkan.

5. Perkaya template DTW. Gunakan beberapa *template* per vowel (mis. hasil *clustering*) atau *template* per speaker sebagai pembanding, serta jarak lokal yang memperhitungkan sebaran fitur (mis. jarak Mahalanobis) untuk membedakan /u/–/o/ dan /i/–/e/ (Tabel 3.6).

6. Perluas evaluasi. Gunakan lebih banyak rekaman uji per speaker dan laporkan uji statistik berpasangan, karena satu rekaman menggeser akurasi satu speaker sebesar 20 poin persentase.

5.3. Pembagian Tugas

Tabel 5.1 memuat pembagian tugas setiap anggota kelompok.

Tabel 5.1. Pembagian tugas anggota kelompok

No	Nama	NIM	Kontribusi
1	Danendra Shafi Athallah	13523136	Modul gaussian.py (estimasi mean dan covariance, NLL, recognition); perekaman 10 rekaman speaker S01; kerangka dan penyusunan laporan.

No	Nama	NIM	Kontribusi
2	Jonathan Kenan Budianto	13523139	Kerangka proyek (struktur repositori, README, requirements), versi awal features.py (MFCC 39 dimensi) dan main.py (pengujian tiga skenario dan tabel akurasi); perekaman 10 rekaman speaker S02.
3	Jovandra Otniel Pangalambok Siregar	13523141	Pemisahan program menjadi modul evaluation.py (pipeline eksperimen, akurasi, confusion matrix) dan reporting.py (tabel dan ekspor prediksi), pembaruan preprocessing.py (pemuatan data rekursif, konversi mono 16 kHz) dan main.py, serta notebook dtw_gaussian.ipynb; penataan data template dan closed beserta perbaikan kode speaker; perekaman 10 rekaman speaker S03.
4	Muhammad Farrel Wibowo	13523153	Modul dtw.py (DTW, averaged template, recognition) dan versi awal preprocessing.py (pembacaan folder per anggota, label huruf kecil); perekaman 10 rekaman speaker S04.
5	Lukas Raja Agripa	13523158	Perekaman 10 rekaman speaker S05 dan penambahan data open speakers (85 rekaman dari kelompok lain) ke repositori.

REFERENSI

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Davis, S., & Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing, 28*(4), 357–366.

Furui, S. (1986). Speaker-independent isolated word recognition using dynamic features of speech spectrum. *IEEE Transactions on Acoustics, Speech, and Signal Processing, 34*(1), 52–59.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362.

Lestari, D. P. (2026). Praktikum: Pengenalan vowel Bahasa Indonesia dengan DTW dan model Gaussian [Slide kuliah]. IF4071 Pemrosesan Ucapan, Institut Teknologi Bandung.

Lyons, J. python_speech_features [Perangkat lunak]. https://github.com/jameslyons/python_speech_features

Sakoe, H., & Chiba, S. (1978). Dynamic programming algorithm optimization for spoken word recognition. *IEEE Transactions on Acoustics, Speech, and Signal Processing, 26*(1), 43–49.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272.